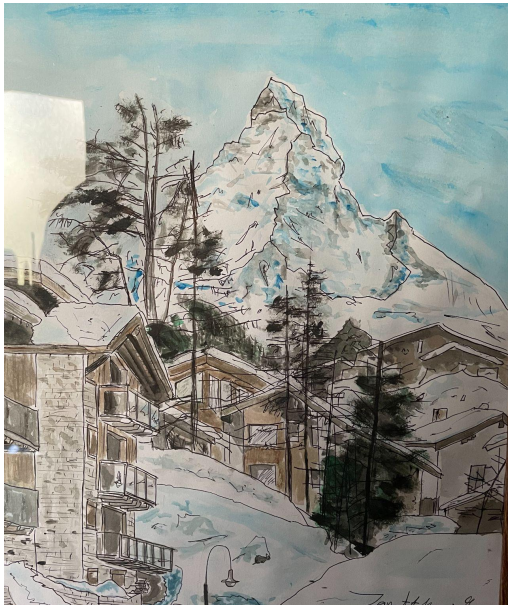
研究室会 発表資料

2026/4/8 松下稜

自己紹介





学部4年　松下稜

出身：静岡県

趣味：散歩/剣道/水彩画

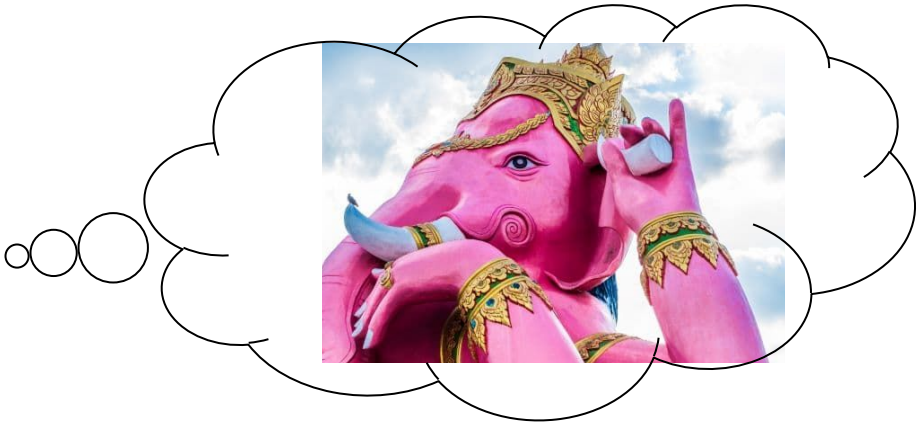
興味：人間の非合理で曖昧な認知現象を

　　題材にLLMの内部表現を解析すること



とりあえずやってみたこと





目的

- 否定指示（「Xを考えるな」）が、LLM の内部表現にどのような影響を与えるかを明らかにする。特に、否定指示が X に関する活性化を本当に抑制できているのか、それとも内部では依然として X を参照してしまうのか。

- affirm / negate / replace の各条件（プロンプト）を比較し、単なる禁止と代替対象の提示とで、内部表現の制御効果にどのような違いがあるかを調べる。LLM に対する指示の与え方として、否定指示と置換指示のどちらがより有効かを考察する。

手法

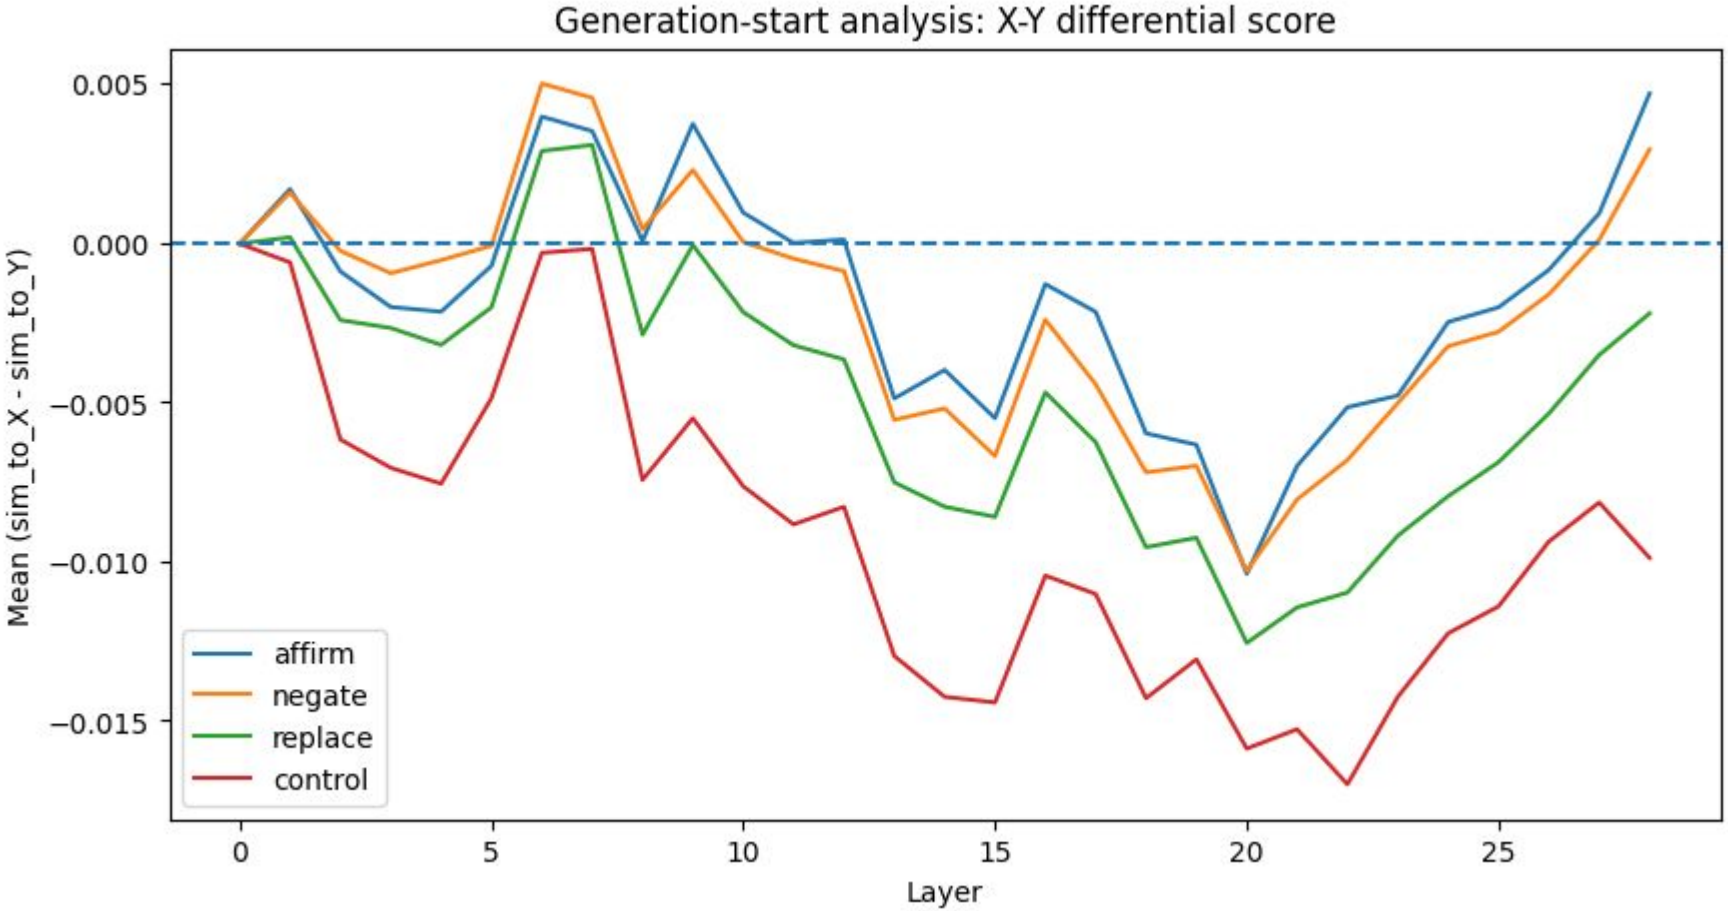
- 各条件(プロンプト)で生成開始前の各層の内部活性(hidden state)を取得する。
- 内部活性とX, Y それぞれのコサイン類似度を計算。sim to X - sim to Y を指標として評価する。値が高いほどX 側に寄った内部表現、低いほどY 側に寄った内部表現と解釈。

- （モデルはQwen2.5-1.5B-Instruct）

X, Y ＝("ピンクのゾウ", "青い小鳥")

４条件　(プロンプトを揃える。短く述べてくださいetc)

Affirm　"{x}の見た目を短く述べてください。"
Negate　"{x}は思い浮かべず、別のものの見た目を一文で書いてください。"
replace　"{x}ではなく{y}を思い浮かべて、その見た目を一文で書いてください。"
control　"{y}の見た目を短く述べてください。"


Generation-start analysis: X-Y differential score
Mean (sim_to_X - sim_to_Y)
0.005
0.000
−0.005
−0.010
−0.015
affirm
negate
replace
control
0
5
10
15
20
25
Layer

結果

- affirm 条件では、予想通り内部表現がX 側に寄った。
- negate 条件も affirm に近い傾向を示し、否定指示であってもX 表現が内部で活性化していることが示唆された。
- replace 条件では、affirm / negate よりも X 側への寄りが弱く、Y 側への誘導が見られた。
- また、条件差は全層で一様ではなく、初期層では差が比較的小さい一方、中間層から後半層にかけて差が明確になった。特に後半層では、affirm と negate が control よりも X 側に寄る傾向が強く見られた。
- これらの結果は、層ごとに役割が異なり、浅い層では入力処理、深い層ではより意味的・出力的な表現形成が進むことがグラフに反映されている可能性を示している。
- 以上より、否定指示だけではX の活性化を十分に抑えられず、置換指示の方がより有効である可能性が示された。

最も似ている論文

- Don’t Think of the White Bear: Ironic Negation in Transformer Models Under Cognitive Load

Wallace, E., Feng, S., Kandpal, N., Gardner, M., & Singh, S. (2023). Findings of the Association for Computational Linguistics (ACL 2023).

否定指示が禁止概念の活性化を逆に高めるという問題設定が、今回の研究と最も近い。

どう似ているか

- 否定は単純な抑制ではなく、まず対象概念を参照してしまう。
- negate が affirm に近づく、という観察と方向性が一致する。

独自性

- 既存研究は出力や rebound を見るものが多い。
- 各層 hidden state と X/Y 類似度 で、内部表現レベル でその現象を見ている。
- したがって、negation blindness / white bear effect の representation-level evidence として出せ