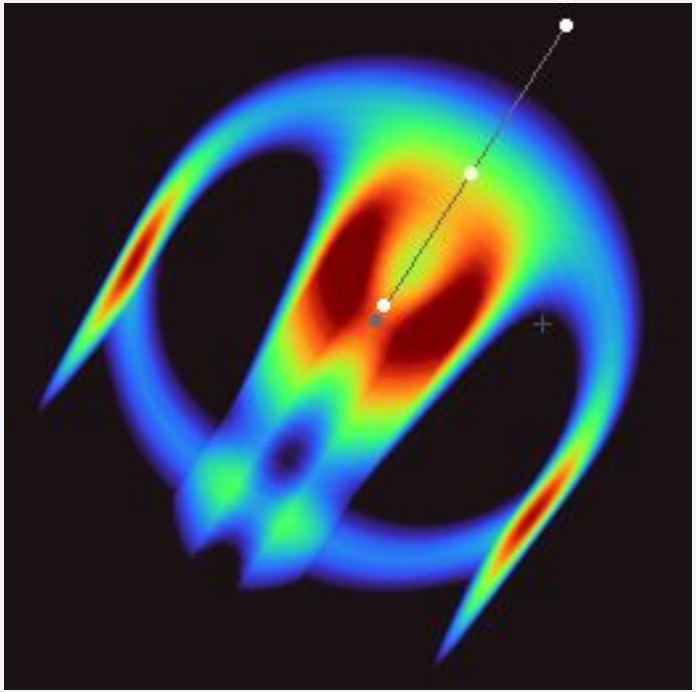
論文紹介

松下稜　7/22

自分の興味1

複雑系・人工生命

単純な局所ルールから、生命のような複雑な振る舞いが創発する現象



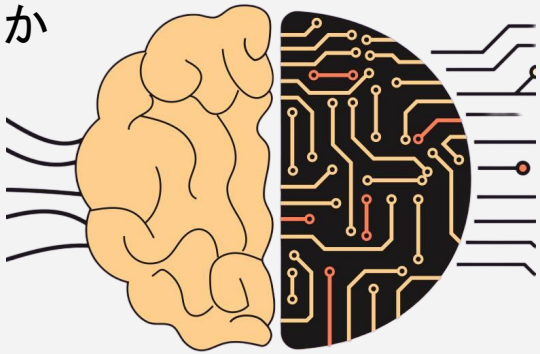
Lenia

自分の興味2

人間心理の不思議→人間とLLM、どこまで同じ、どこから違う？

hidden stateを調べることで、人間とLLMの共通点・相違点を考えたい

LLMにも、出力には現れない内部的な判断や確信があるのか



論文概要

題名 : Reasoning Models Know When They’re Right: Probing Hidden States for Self-Verification.

著者 : Anqi Zhang et al.

公開日 : 2025/4/7

Conference on Language Modeling 2025

https://openreview.net/pdf?id=O6I0Av7683

推論途中の隠れ状態から正誤を判定し、精度を保ったまま不要な思考を止めることで推論トークンを最大24%削減できた

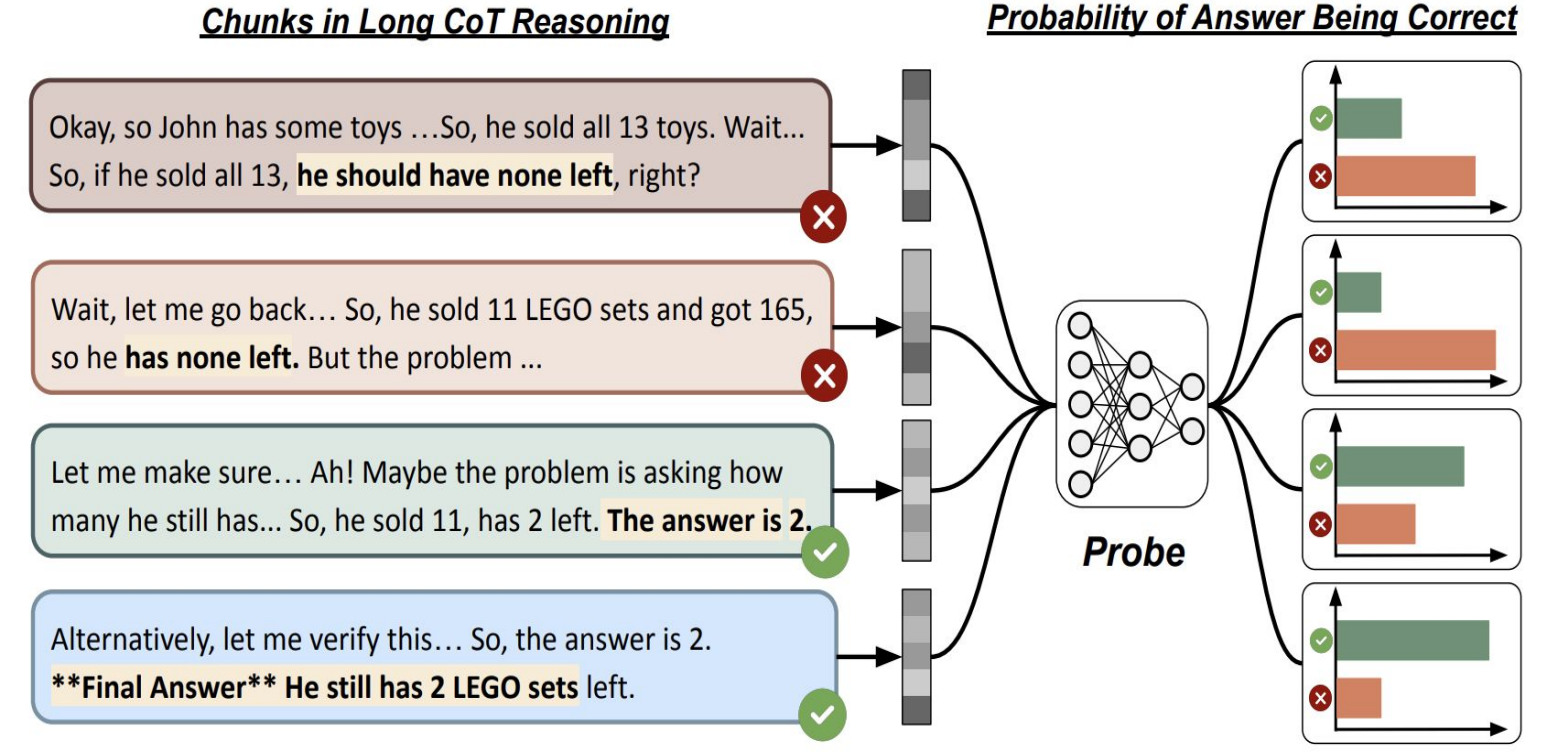
問題設定とアイデア

Reasoning modelは、CoT中で複数の**中間回答**を生成する

しかし、正解に到達した後も推論を続ける **overthinking** が起こる

各中間回答時点のhidden stateから、回答の正しさを予測できるか調査

問題設定とアイデア



Long CoTを中間回答ごとに区切り、hidden stateから正解確率を推定する

手法概要　hidden stateから正解確率を予測

学習時

1. CoTを中間回答ごとに分割

2. 中間回答を正解と照合し、**正誤ラベル**を付与(gemini)

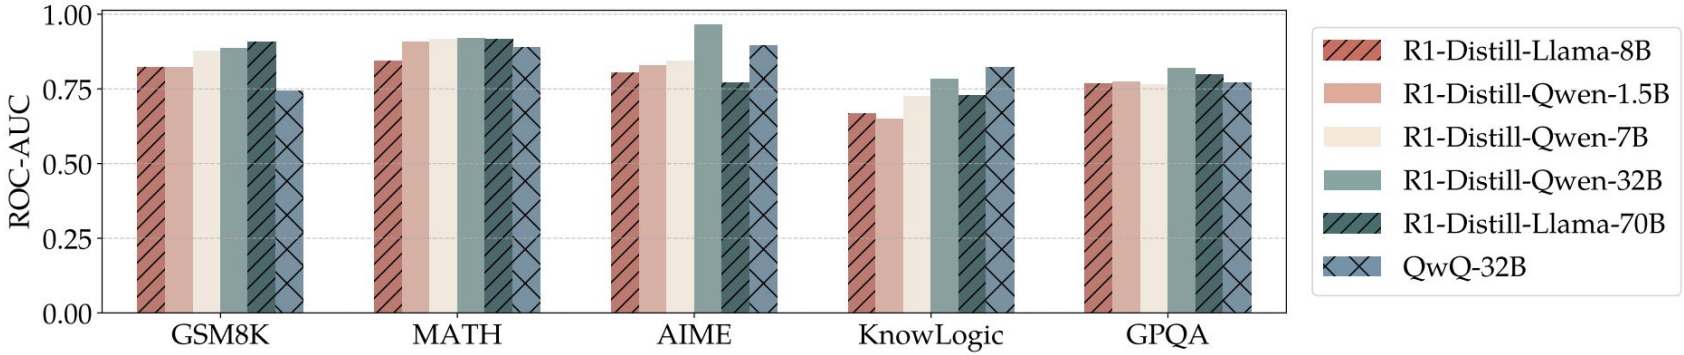
3. chunk末尾の**hidden state**と正誤ラベルでprobeを学習

推論時

4. Probeが各中間回答の正解確率を予測

5. 確率が閾値を超えたら、その回答で**early-exit**

実験結果1　タスク・モデル別の正誤識別性能



1.0：完全に区別できる
0.5：ランダム判定と同じ
< 0.7：ある程度区別できる

GSM8K：算数の文章問題
MATH：難しい数学問題
AIME：数学コンテスト問題
KnowLogic：論理推論
GPQA：大学院レベルの科学問題

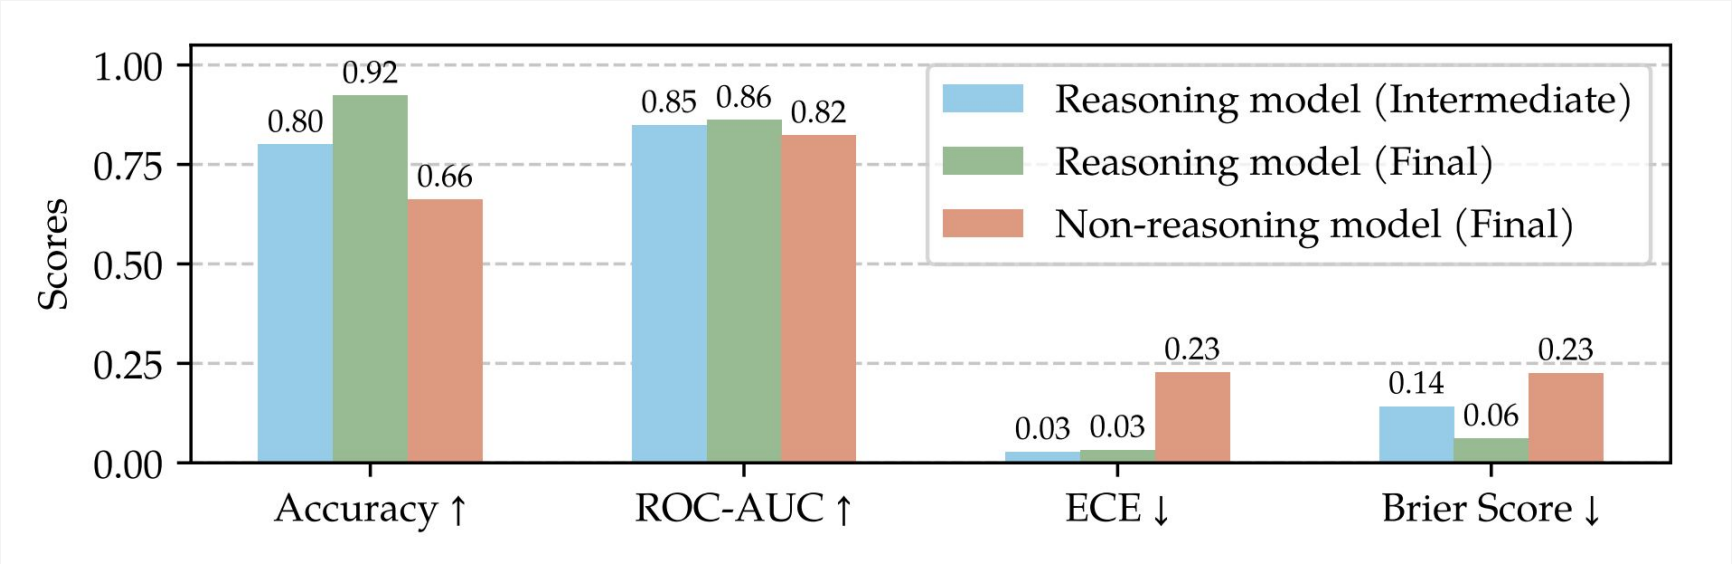
各中間回答を生成した時点の hidden stateに、中間回答が正しいか誤っているかをprobeがある程度予測できる情報が含まれていた

多くの設定で ROC-AUC 0.7以上

数学タスク間では、別データセットにもある程度一般化

(Probeは学習したモデルやデータセットに一定程度依存する)

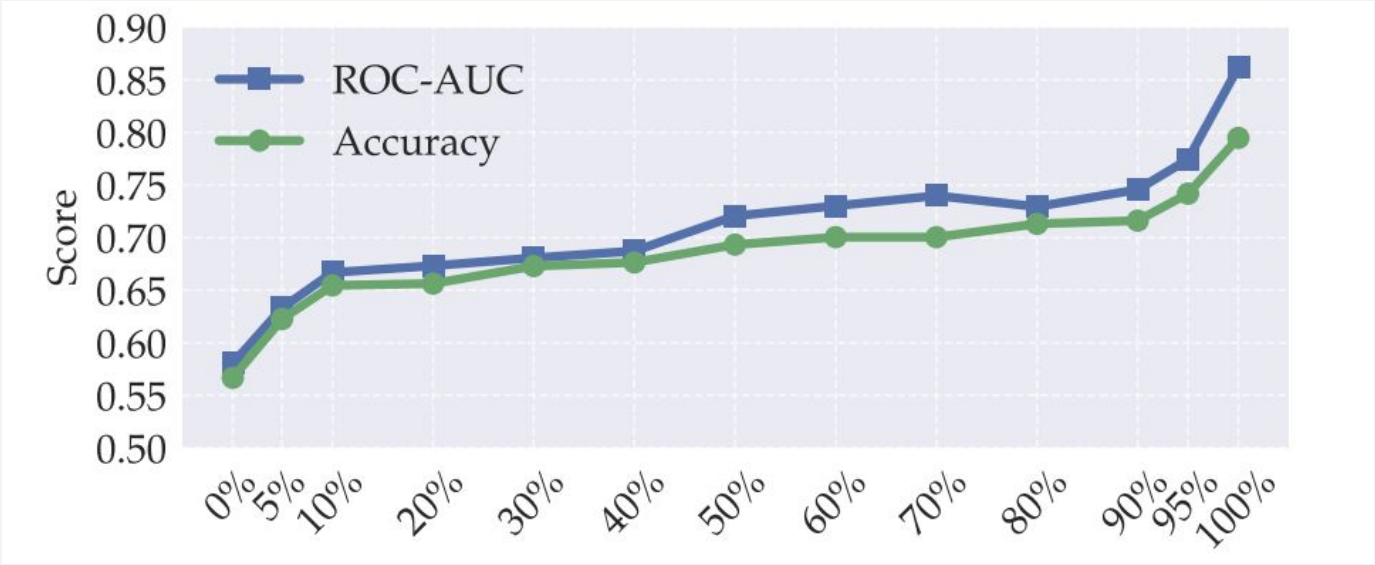
実験結果2　Reasoning modelと通常モデルの比較



Reasoning modelでは、より回答の正誤を高精度に予測できる

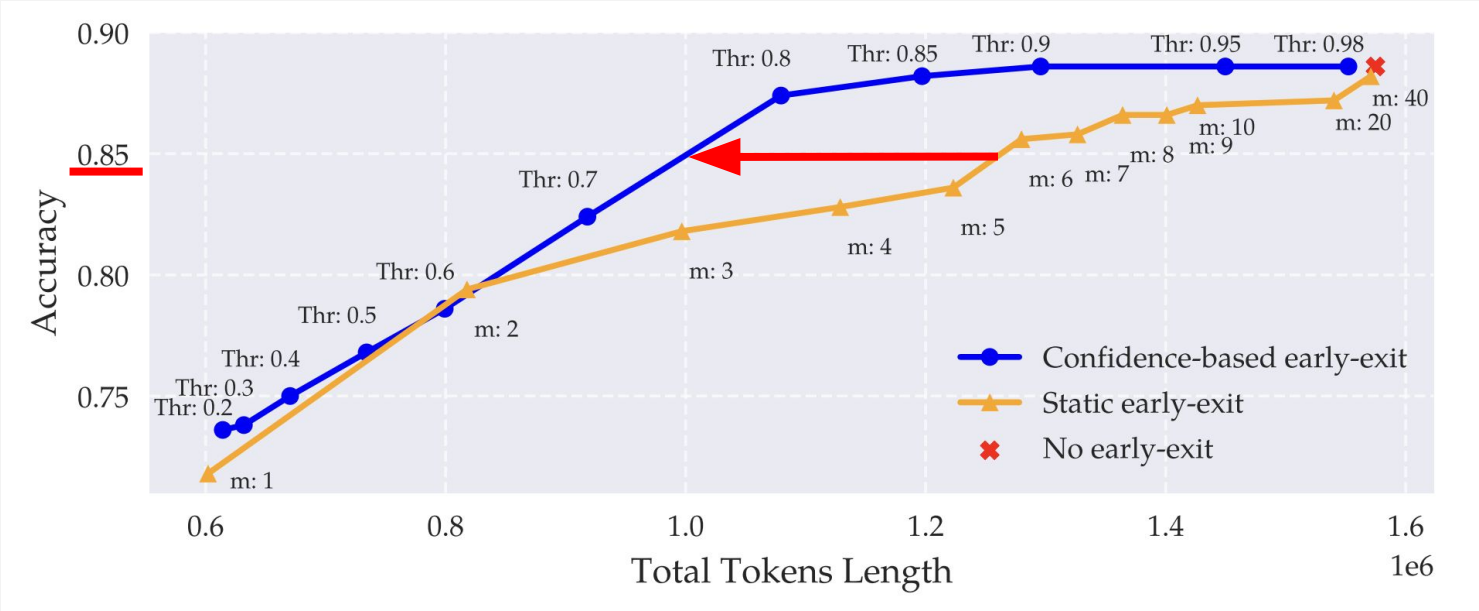
特にECEが低く、正解確率の信頼性が高い

実験結果3　思考の進行と正誤予測性能



中間回答を明示的に出す前でも、hidden stateから将来の回答の正誤をある程度予測できる
回答に近づくほど、予測性能と確率の信頼性が向上する。

実験結果4　精度と推論トークン数の関係



Probeの正解確率を停止判定に使うことで、固定位置で停止する方法より良い精度・効率のバランスを実現

閾値0.85では、精度をほぼ維持しながら推論トークンを約24%削減

今後の方向性

自由回答問題で実験

人間の直感・確信・迷いと、LLMの内部状態はどこまで対応するのか