意味的距離の測定と予備実験

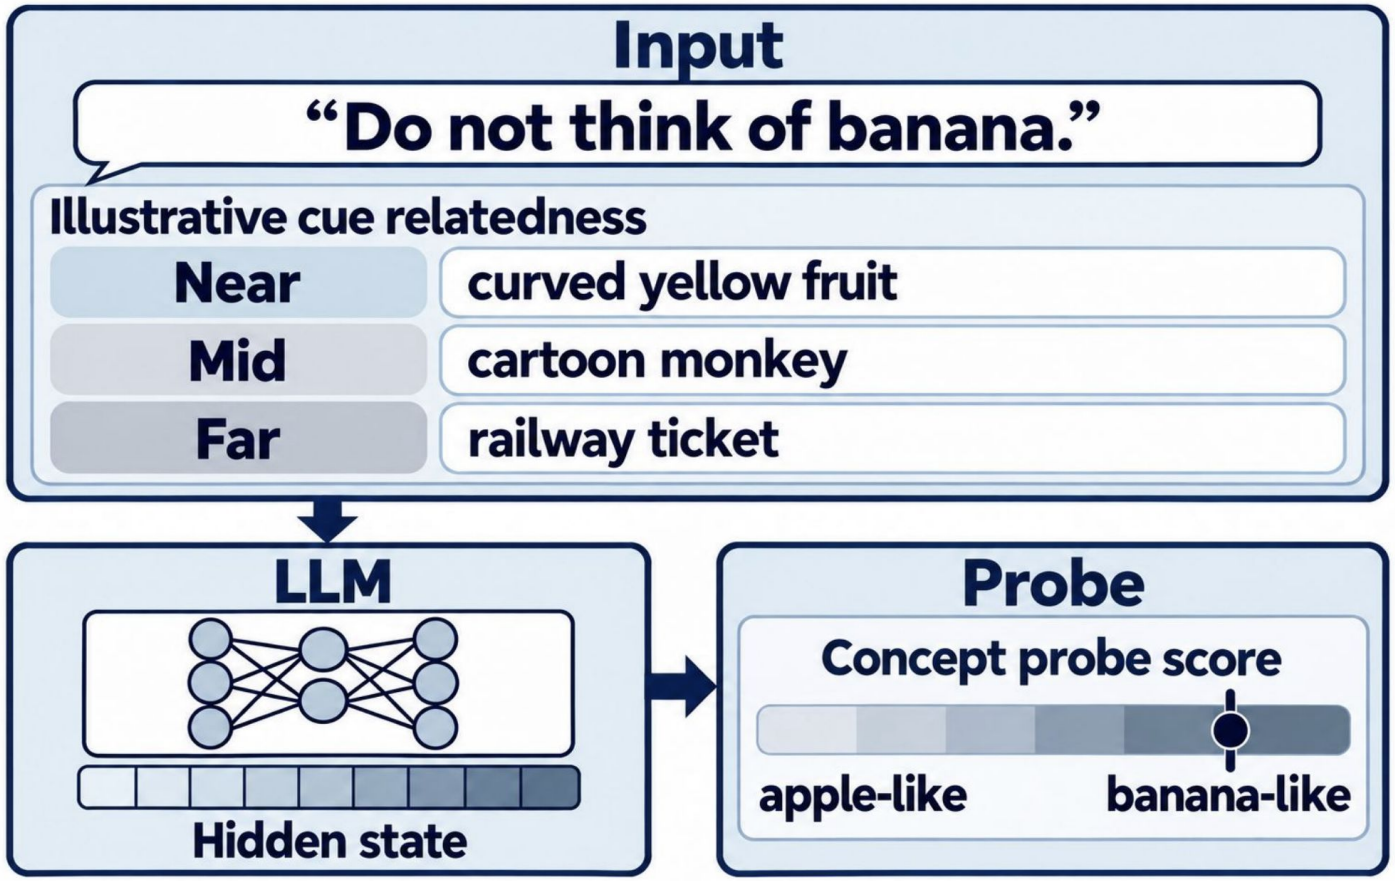
Semantic Distance as a Metric & Pilot Validation

松下稜 / 2025.11.04

リサーチクエスチョン

手がかり（Cue）と対象概念（Target）の意味的距離は、

LLM の内部表現にどう影響するか？



意味的距離とは？

2つの単語が概念的にどれくらい近いかを表す連続的な指標

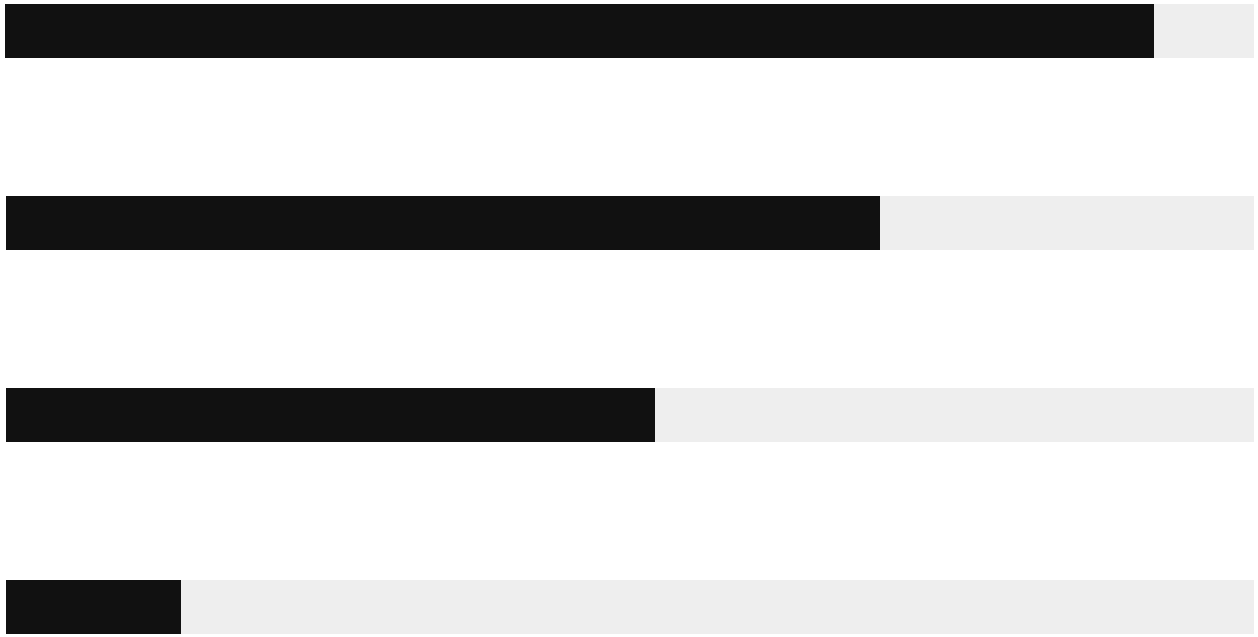
例：Target = elephant

Mammoth 意味的に類似

Trunk 特徴に関連

Safari 状況的に関連

Algorithm 関連が弱い



コサイン距離による測定

1. ベクトル化（Encode）

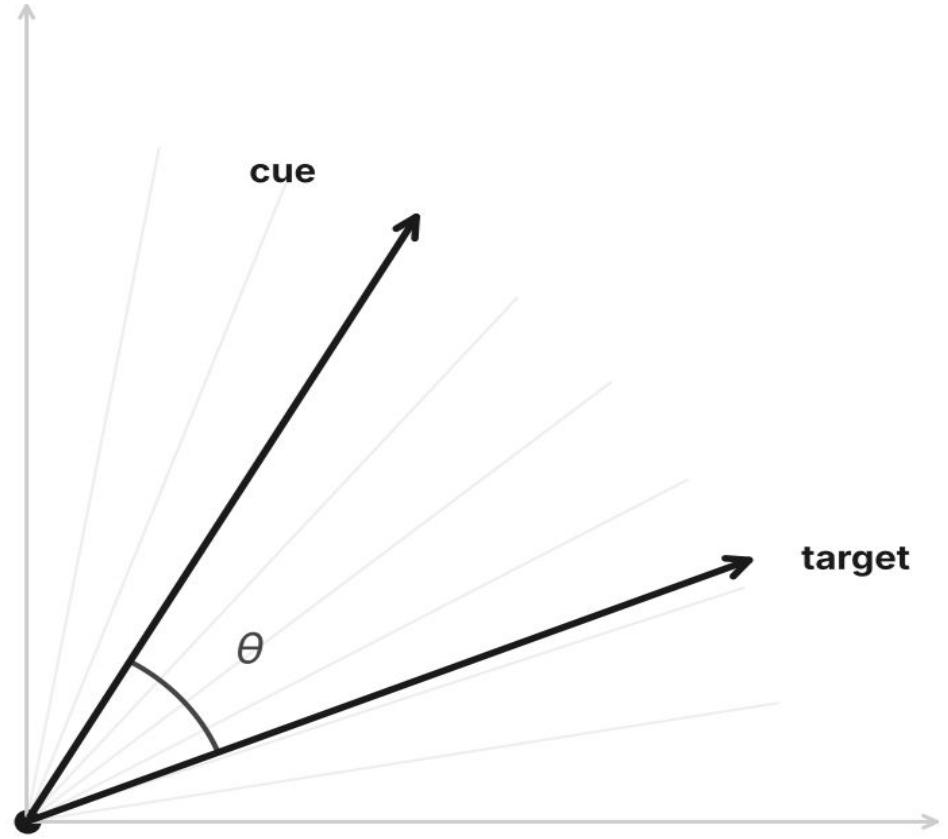
Target と Cue を埋め込みベクトルに変換

2. コサイン類似度（Cosine similarity）

cos(target, cue) = (A · B) / (|a| × |b|)

3. コサイン距離（Cosine distance）

d(target, cue) = 1- cos(target, cue)



使用モデル

all-mpnet-base-v2

768次元 / 英語 / オープンソース

選定理由

- 意味類似度モデルとして最高品質
- Qwen とは独立したモデル（測定の交絡を回避）
- オープンソースで再現可能

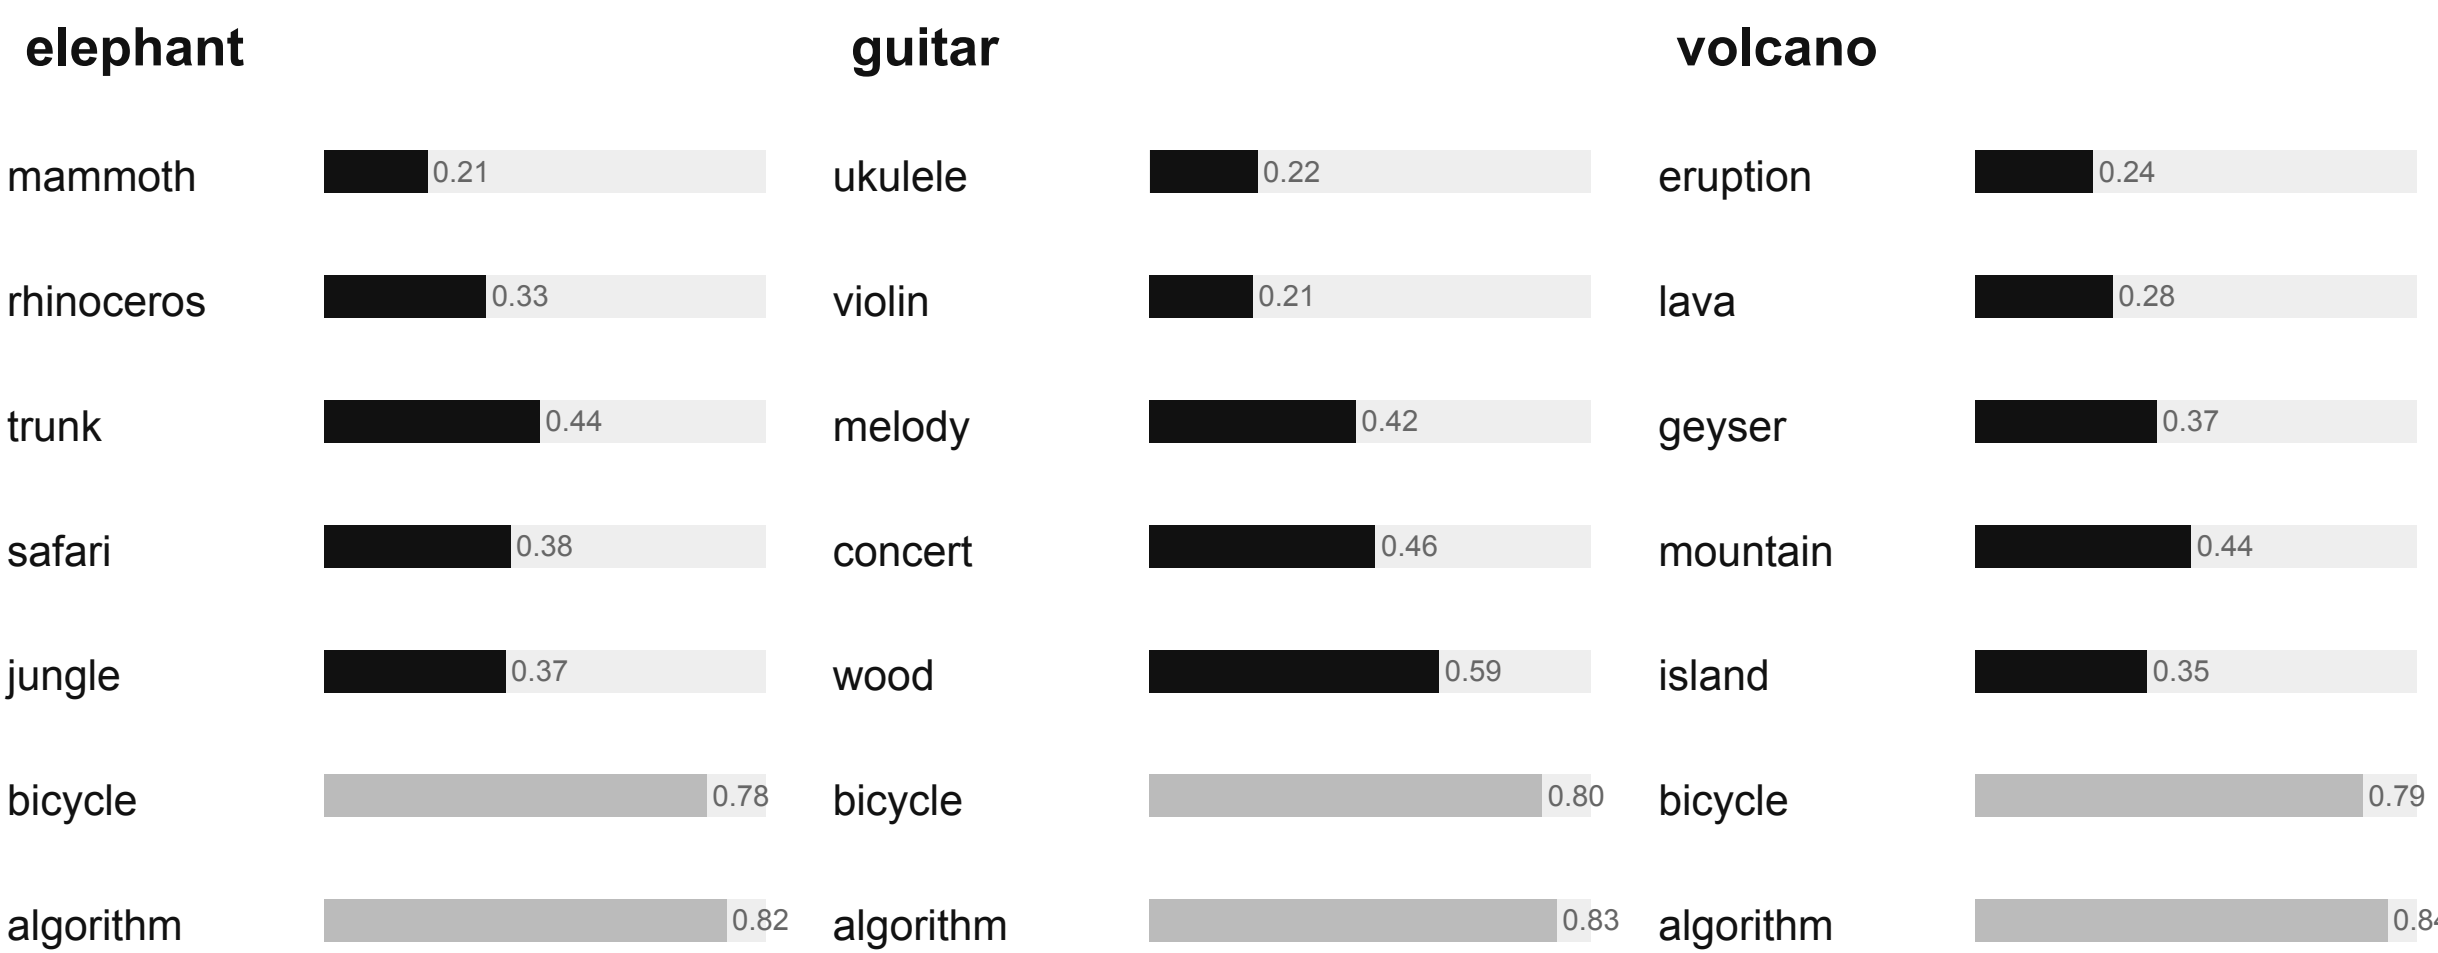
注意：単語単体への適用可否、人間の連想との対応については要検証

予備実験：設定

意味的距離の異なる Cue を体系的に構成できるか？

Target	← 近（Near）	Cue 2	Cue 3	遠（Far）→
elephant	mammoth	trunk	safari	bicycle
guitar	ukulele	melody	concert	bicycle
volcano	eruption	geyser	mountain	bicycle

結果：コサイン距離スコア



近い Cue は低スコア（想定通り）　ただし一部の順位は直感と異なる

主な発見

elephant: jungle < trunk

guitar: violin < ukulele

volcano: island < geyser

コサイン距離は有効
ただしモデルの距離 ≠ 私の直感

議論

意味的距離の定義は理論的に妥当か？

単語単体の Embedding 検証で十分か？

4段階の距離設定をどうするか

Cue による内部表現の変化をどう評価するか？

Probe の識別性能

目的

他の Cue でも概念を正しく識別できるか？

ゾウ

以前：柔軟な鼻を持つ、とても大きな陸上動物
新　：飼育員は、大きな動物が鼻を使って餌をつかむ様子を見ていた

バナナ

以前：手で皮をむく黄色い果物
新　：淡い色の薄切りをいくつか加えると、ミルクシェイクが濃厚で甘くなった

結果

- バナナ・ゾウで AUC 低下
- ピアノは識別性能を維持
- 20ペアへの拡張で安定性に課題

Cue を変えたときの Probe 識別性能

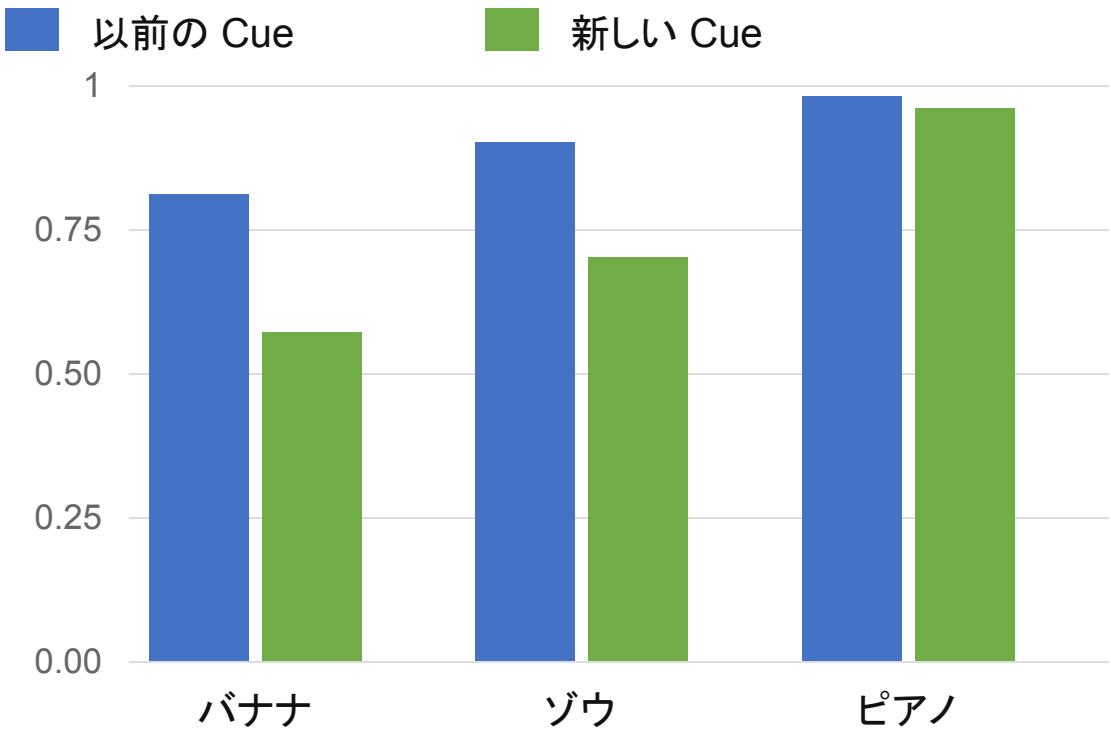


Fig.1 ROC-AUC 比較（層22–23の平均）。AUC が1に近いほど識別性能が高い。

Probe の識別性能は、使用する Cue によって変化

意味的距離と内部表現（予備実験）

目的

Cue と Target の意味的距離は内部表現に影響するか？

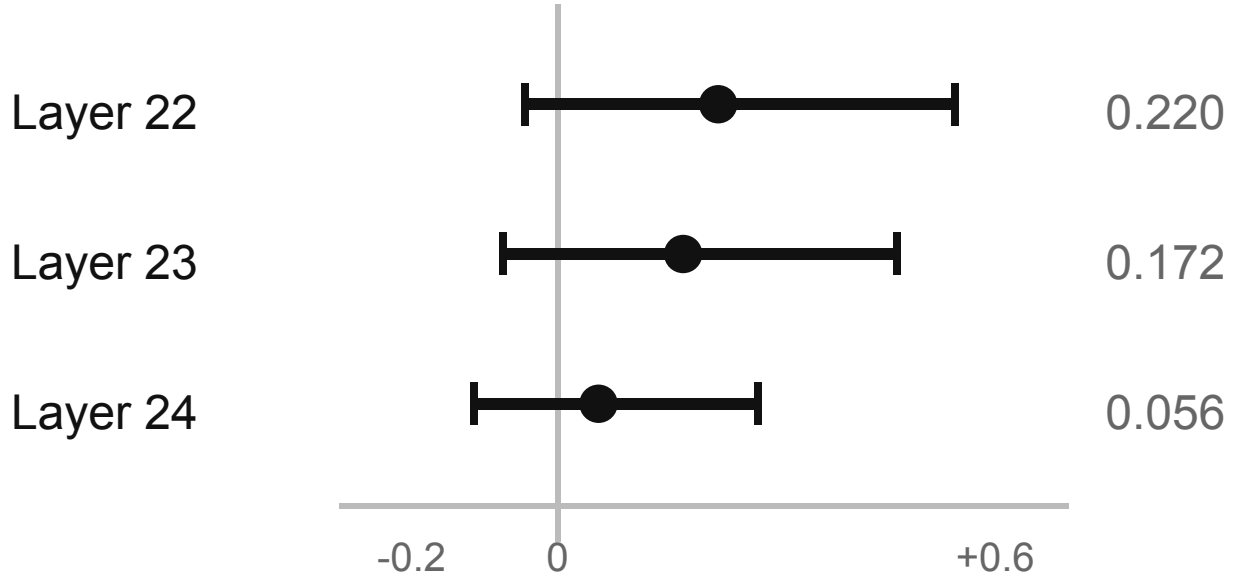
方法

- モデル：Qwen2.5-0.5B-Instruct
- 8概念ペア
- 抑制指示下での Probe 反応 vs. コサイン距離

結果

- 抑制指示により識別スコアの差が縮小
- 意味的距離による明確なパターンは未確認

距離が Probe 反応に与える効果
（傾き + 95%CI、8概念ペア）



抑制効果は観察されたが、意味的距離との関係はまだ不明確